

"TECHNO DU BIG-DATA »

Open Data et Linked data

Stéphane Derrode, Dpt MI -
stephane.derrode@ec-lyon.fr



OPEN DATA

Open Data, c'est quoi?

- L'***open data*** ou **donnée ouverte** est une donnée numérique dont l'accès et l'usage sont laissés libres aux usagers. Elle peut être d'origine publique ou privée, produite notamment par une collectivité, un service public ou une entreprise. Elle est diffusée de manière structurée selon une méthode et une licence ouverte garantissant son libre accès et sa réutilisation par tous, sans restriction technique, juridique ou financière.
- L'ouverture des données (*open data*) est à la fois un mouvement, une philosophie d'accès à l'information et une pratique de publication de données librement accessibles et exploitables.
- Elle s'inscrit dans une tendance qui considère l'information publique comme un bien commun dont la diffusion est d'intérêt public et général.

La loi (en France...)

- **1978** Loi n. 78-753 / Crédation de la Commission d'accès aux documents administratifs (CADA). Objectif : faciliter et contrôler l'accès des particuliers et des organisations privées aux documents administratifs.
- **2007** Directive européenne INSPIRE, visant à établir une infrastructure d'information géographique dans la Communauté européenne pour favoriser la protection de l'environnement. Elle s'applique aux données géographiques détenues par les autorités publiques, dès lors qu'elles sont sous forme électronique et qu'elles concernent l'un des 34 thèmes figurant dans les annexes de la directive.
La directive INSPIRE a été transposée dans le droit français par l'ordonnance 2010-1232 du 21 octobre 2010, apportant des modifications au code de l'environnement.
- **2015** Loi n. 2015-1779 ("Valter") / Instauration d'un principe de gratuité par défaut de l'information publique.
- **2016** Loi n. 2016-1321 ("pour une République Numérique", "Lemaire") / Ouverture par défaut des données publiques et d'intérêt général (disposition entrée en vigueur le 7 octobre 2018), service public de la donnée, . . .

L'open data en France

- <https://www.data.gouv.fr>
- <https://www.data.gouv.fr/fr/organizations/>
- <https://geo.data.gouv.fr>
- <http://www.opendatafrance.net>
- <https://airtable.com/shrmZOh5If14Q1PVN/tblwkJPsyayeH5IX>
- <https://airtable.com/shr3IYfHZW1cVTS3s/tbIVtTOudK5Ygpsmj>
- <https://dataactivist.coop/fr/>



Quelles données ?

Toutes les données structurées et produites par des acteurs publics ou privés dans le cadre d'une mission de service public. Cette définition s'étend aux données décrivant l'espace, les services publics et l'exercice politique, produites par des acteurs non institutionnels : associations, citoyens engagés, acteurs économiques ou académiques.

Sont exclus de l'opendata

- Les données à caractère personnel

« Constitue une donnée à caractère personnel toute information relative à une personne physique identifiée directement ou indirectement par référence à un ou plusieurs éléments qui lui sont propres » (la loi 78-17 du 6 janvier 1978 art 2)

Ex : nom, adresse, photographie, num. tél., num. d'identifiant, adresse IP, adresse électronique...

- les documents administratifs dont la consultation ou la communication porterait atteinte :

A-6a) Au secret des délibérations du Gouvernement et des autorités responsables relevant du pouvoir exécutif ;

A-6d) A la sûreté de l'Etat, à la sécurité publique ou à la sécurité des personnes;

A-10c) Ou sur lesquels des tiers détiennent des droits de propriété intellectuelle.

Données publiques versus Big Data

Données publiques : services publics, intérêt général, ouvertes

- Effectifs: d'agents municipaux, d'élèves
- Horaires : bus et tram en temps réel,
- Patrimoine : arbres, équipements sportifs, points lumineux, bornes fontaines ...
- Éléments liés à l'exploitation : livres empruntés dans les bibliothèques, budget et compte administratif, marchés publics
- Description du territoire : photo aérienne, altimétrie, description des rues,
- Reflet de la vie locale : mariage, naissance, prénoms, élections, agendas...

Big data: données personnelles, comportement individuel, données privées

- Traces (téléphone mobile, connexion)
- Navigation internet, réseaux sociaux, messagerie,
- Achats (CB), déplacements individuels ou collectifs (badge, carte)
- Consommations individuelles (eau, électricité, ..)
- Objets connectés

 PIONNIERS
MOS

CAPITALE

The image shows a screenshot of the Brocas OpenData website. The header features the 'Brocas OpenData' logo with a green globe icon. Below the header, there's a search bar with placeholder text 'Rechercher une commune'. A large, bold, black diagonal banner across the center of the page reads 'COMMUNES RURALES'. In the bottom left corner, there are icons for 'Département', 'Wikipedia', and 'Carte'. On the right side, there's a sidebar with sections like 'Qui sommes-nous', 'Actualités', 'Méthodologie', 'Glossaire', 'Contact', and 'FAQ'. The background of the main content area shows a scenic view of a village with houses and trees under a blue sky.

COMMUNES RURALES

The screenshot shows the homepage of the Open Data PACA website. At the top, there's a navigation bar with links for Accueil, Objets, Cencoses, Données, Licences, Apps, MP2015, Partenaires, Glossaire, and Contact. Below the navigation, there's a section titled "Actualités" with a yellow circular graphic containing text. A large black diagonal banner across the middle of the page contains the word "REGION". The main content area features a "Open Data public et à l'échelle comme levier pour les démarches de développement durable" section with a "Lundi 10 novembre 2014 - 10h30-12h30" event listing. At the bottom, there are sections for "Données" and "Applis les meilleures".

REGIONS
SOCIO-ECONOMIC

ORIGINAUX

A screenshot of the Data Publica website. At the top, there's a blue header bar with the logo 'DATA PUBLICA' and several menu items: 'ACCUEIL', 'PROJETS & SERVICES', 'STRATEGIE', 'CONTACTS', 'BLOG', and 'CONTACT'. Below the header, a large banner reads 'Data Publica lauréat du Concours INNOVATION 2030 CONCOURS MONDIAL D'INNOVATION' with a red and blue circular logo. A black diagonal banner across the middle contains the word 'PRIVES' in large white letters. Below this, there are four circular icons with numbers 1, 2, 3, and 4, each with a short description: 'Concours 2008 - Un rôle de plus pour les autorités publiques', 'Concours 2009 - Nouvelles technologies au plus près des besoins des plus autorisées', 'Concours 2010 - Acte innovant 2010 - concours à déclarer - innovation à votre disposition', and 'Concours 2011 - Nouveaux horizons 2011 - concours à déclarer - innovation dans les marchés publics et privés'.

PRIVES

The screenshot shows the main interface of the data.gouv.fr website. At the top left is the French flag logo and the site's name. A navigation bar includes links for "Accéder à l'ensemble des données", "Rechercher", "Télécharger", "S'inscrire", and "Connexion". The top right features a "Plateforme ouverte des données publiques françaises" link and a "Créer une nouvelle inscription" button. Below the header is a search bar with placeholder text "Recherche". To its left is a sidebar with sections for "Agriculture et Alimentation", "Culture", "Économie et Emploi", "Éducation Nationale", "Intérieur et Justice", and "Sécurité et Défense". The main content area features a large banner with the text "Partagez, améliorez et réutilisez les données publiques" and a prominent black diagonal band containing the word "L'ETAT". Below the banner is a "DÉMARRER" button. The bottom section displays a grid of data visualizations under the heading "MEILLEURES PUBLICATIONS", including a map of France with colored regions and a grid of colored squares representing data. A sidebar on the right lists "DERNIÈRES PUBLICATIONS" with links to "Décret relatif aux données publiques", "Décret relatif à la publication de l'ensemble des données publiques", "Bureau de recherche Prospective Interministérielle", "Bureaux d'Innovation", and "Portail des Services de l'Etat pour les Réalisations Éducatives".

L'ETAT

ASSOCIATIONS

Gisement de données : exemple

- **Collectivités territoriales :**

- <https://fr.wikipedia.org/wiki/OpenDataFrance>

- **EtaLab (Ministères) :** <http://data.gouv.fr>

- **Citoyens :**

- Data4citizens (<https://open.data4citizen.com>),
 - Regards Citoyens (<https://www.regardscitoyens.org>),
 - DataPublica (<https://www.data-publica.eu>)

- **Instituts :**

- INSEE : <https://www.insee.fr/fr/statistiques>
 - INPI : <https://www.inpi.fr/fr/services-et-prestations-domaine/open-data>

- **Agences de l'air, de l'eau, etc. :**

- Pollution (échelle mondiale) : <https://openaq.org>
 - Pollution (région Auvergne-Rhône-Alpes) :

- <https://www.atmo-auvergnerhonealpes.fr/donnees/telecharger>

Formats

- **Pour être Opendata, les données doivent être :**
 - au format électronique,
 - accessible sur internet,
 - structurées,
 - à un format ouvert (et de préférence non propriétaire).
- **Types de format des fichiers disponibles**
 - Données alpha-num. : csv, ods, xls, doc, xml, JSON...
 - Un document au format pdf, même full text –et pas image- est lisible par une machine mais n'est ouvrable que par Acrobat/Adobe, donc non Opendata
 - Données géographiques : Shape, GéoJSON, KML, KMZ,
 - Format propriétaires non ouverts : DWG et DXF (Autocad)
 - Format spécifiques :
 - Domaine Transport : GTFS, Chouette, NetEX, Neptune...
 - GPX (ouvert), ...

Accès par API

- **Données temps-réel**
 - Horaire, charges, disponibilité, ...
- **Données statiques** mais à jour à tout instant
 - Accès direct à une cellule, à une ligne d'un tableau par ex.
- Il existe des **portails** qui ont systématisé la publication des données sous forme de fichiers ET d'API

The screenshot shows a web browser window for data.toulouse-métropole.fr. The page title is "DATA.toulouse-métropole" and the subtitle is "Le portail des données ouvertes du territoire". The navigation menu includes Démarche, Licence, Données, Cartes, API (highlighted), Communes, Réutilisations, and Demande. Below the menu, there are two tabs: "V1" and "V2 (beta)". Under "V1", there are links for "Console" and "Documentation". The main content area is titled "Lister les jeux de données" and shows a "GET /api/datasets/1.0/search/" endpoint. It includes search fields for "Requête en texte intégral" and "Code langue de 2 lettres", and a "rows" dropdown set to 10. A large "Submit" button is at the bottom.

The screenshot shows a web browser window for opendata.paris.fr. The page title is "PARISDATA" and the subtitle is "MAIRIE DE PARIS". The navigation menu includes Les données, L'API (highlighted), La licence, and La démarche. Below the menu, there are tabs for "Cartographie" (selected) and "V2 (beta)". The main content area is titled "Console API" and states "La référence SWAGGER complète est disponible en [JSON](#) et [YAML](#)". It shows a tree view of operations under "root" and "metadata". Under "root", there is a single "GET /" operation. Under "metadata", there are three "GET" operations: "{source}/metadata_templates", "{source}/metadata_templates/{metadata_template_type}", and "{source}/metadata_templates/{metadata_template_type}/{metadata_template_name}". Each operation has "Show/Hide", "List Operations", and "Expand Operations" links.

Outils d'exploitation

Données Alphanumériques

- Suites bureautiques habituelles : OpenOffice, Libre Office,
 - Et les outils commerciaux habituels (Google, MS, ...)
- De nombreux outils en ligne : ConversionTools Services (xml<>csv...)
- Les langages de programmation habituels : C, Python...
- <https://openrefine.org> pour l'exploration et le retraitement des données
- Frise Chronologique

Données géographiques

- QGIS : vraie suite logicielle de géomatique (SIG), convivial
- UMAP, Carto, MapServer, GéoServer : manipulation des cartes

Données cartographiques

- **Visualisation**

- OSM: <https://www.openstreetmap.org>
Démonstration : <http://tools.geofabrik.de>

- **Edition / Modification**

- <http://openstreetmap.fr/>
- <http://open.mapquest.fr>
- <https://umap.openstreetmap.fr/fr/>

- **Exploitation**

- Routing : <http://www.yournavigation.org>,
<http://map.project-osrm.org>,
- OverPassTurbo : <http://overpass-turbo.eu>

LINKED DATA

1. Web des données, *Linked Data*
2. *Resource Description Framework (RDF)*
3. SparQL

1. LOD : Qu'est-ce que le Web ?

Un espace documentaire décentralisé, interconnecté, interopérable et *évolutif*.

- décentralisé → **HTTP 2014, HTTP 2.0**
- interconnecté → **URL, URI, IRI**
- interopérable → **HTML5, CSS, JS**

Vers un Web de données

Un espace **de données** décentralisé, interconnecté et interopérable.

- décentralisé → **HTTP**
- interconnecté → **URL**
- interopérable → ?

1. LOD : Web de ressources

Le web est constitué de **ressources**, par exemple :

- le bulletin météo du jour pour Lyon
- le bulletin météo du jour pour le lieu courant
- ma commande de café de jeudi dernier

Chaque ressource est identifiée par un IRI
(*Internationalized Resource Identifier*), e.g.:

- <http://meteo.example.com/lyon>
- <http://meteo.example.com/ici>
- <http://commerce.example.com/commande/192837>

1. LOD : Web de ressources

Une ressource n'est pas un simple fichier, dont on récupèrerait le contenu.

Elle est un objet *actif*, avec lequel on interagit.

- le bulletin météo du jour pour Lyon :
→ le contenu change régulièrement
- le bulletin météo du jour pour le lieu courant :
→ le contenu dépend de plus du contexte de l'utilisateur
- ma commande de café de jeudi dernier :
→ on peut agir dessus (par exemple pour l'annuler)

1. LOD : Ressources et représentations

- Une ressource n'est jamais manipulée directement, mais toujours à travers des **représentations** (pour la créer, la consulter, la modifier).
- Les représentations d'une ressource peuvent varier en fonction
 - de son état
 - de l'agent qui manipule la ressource (négociation de contenu, contexte)

représentation :	utilisable par :
texte (HTML...)	humains, moteurs de recherche
médias (image, son...)	<i>surtout</i> humains
données structurées	machines

1. LOD : Ressources et représentations

- Une ressource n'est jamais manipulée directement, mais toujours à travers des **représentations** (pour la créer, la consulter, la modifier).
- Les représentations d'une ressource peuvent varier en fonction
 - de son état
 - de l'agent qui manipule la ressource (négociation de contenu, contexte)

représentation :	utilisable par :
texte (HTML...)	humains, moteurs de recherche
médias (image, son...)	<i>surtout</i> humains
données structurées	machines

1. LOD : de HTML à XML

XML (*eXtensible Markup Language*) a été recommandé par le W3C en 1998. L'objectif était de pallier la sémantique « faible » de HTML.

```
<!-- HTML -->
<a href="http://champin.net/">
  Pierre-Antoine <strong>Champin</strong>
  (<em>Maître de conférences</em>)</a>
```

```
<!-- XML -->
<Person homepage="http://champin.net/">
  <givenName>Pierre-Antoine</givenName>
  <familyName>Champin</familyName>
  <job>Maître de conférences</job></Person>
```

1. LOD : de XML à RDF

- Le modèle sous-jacent de la syntaxe XML est un arbre (*XML Infoset*), ce qui n'est pas adapté à la structure décentralisée du Web.
- L'objectif du *Resource Description Framework* (RDF), recommandé par le W3C en 1999, vise à munir le Web d'un modèle de données plus adapté, ayant une structure de *graphe*.
- L'objectif est de construire le *Semantic Web* : un web dans lequel les machines ont (enfin) accès à la sémantique des données.
- Recommandation un peu hâtive, présentant quelques défauts importants (notamment l'absence de sémantique formelle).
→ faible adoption de RDF



1. LOD : de RDF à RDF


- En 2004, le W3C publie un nouvel ensemble de recommandations sur RDF pour remplacer celles de 1999.
- Pour des raisons de compatibilité avec l'existant, certains aspects sont conservés malgré les débats qu'ils suscitent, mais les défauts considérés comme majeurs sont corrigés.
- Après cet échec relatif, l'appellation *Semantic Web* tombe peu à peu en disgrâce. Certains défenseurs de RDF parlent plus modestement de *Data Web*, puis de *Web of Linked Data* (2006).
- En 2014, RDF est plus largement accepté. Le W3C publie une version révisée (RDF 1.1), endossant notamment plusieurs syntaxes concrètes.

1. LOD : Raw Data Now!

- The next Web,
https://www.ted.com/talks/tim_berners_lee_the_next_web



1. LOD : Linked open Data



Source image : Richard Cyganiak (<https://lod-cloud.net>)

1. LOD : Linked open Data

Les quatre principes de Linked Data


1. Utiliser des IRIs pour nommer les choses (= ressources).
2. Utiliser des IRIs HTTP pour pouvoir obtenir des *représentations* de ces ressources.
3. Fournir ces représentations en utilisant des langages et des protocoles standards ([RDF](#), [SPARQL](#)).
4. Inclure des liens pour permettre de découvrir de nouvelles ressources.

d'après Tim Berners Lee,

<http://www.w3.org/DesignIssues/LinkedData.html>

1. LOD : Linked open Data

Linked open data [star scheme \(<https://5stardata.info/en/>\)](https://5stardata.info/en/)



1. LOD : Projet emblématique, DBPédia

- Projet lancé par Chris Bizer en 2007.
- Objectif : extraire les informations structurées (*infobox*) présentes dans Wikipedia pour les exposer en RDF.
- En novembre 2015 :

The English version of the DBpedia knowledge base describes 4.58 million things, (...) including 1,445,000 persons, 735,000 places (including 478,000 populated places), 411,000 creative works (including 123,000 music albums, 87,000 films and 19,000 video games), 241,000 organizations (including 58,000 companies and 49,000 educational institutions), 251,000 species and 6,000 diseases.

1. Projet emblématique : DBPédia

Screenshot of the Wikipedia page for Lyon (French city) on the English Wikipedia.


The page title is "Lyon". The main content area starts with a summary: "This article is about the French city. For other uses, see [Lyon \(disambiguation\)](#).
Lyon (Arpitan: *Lyon*), often *Anglicized* as *Lyons*, is a city in east-central France in the region Rhône-Alpes, situated between Paris and Marseille. Its name is pronounced [ljɔ̃] (listen) in French and Arpitan, and /iːˈbɒn/ or /iːən.ɛnz/ in English. Lyon is located at 470 km from Paris, 320 km from Marseille, 160 km from Geneva, 280 km from Turin, 450 km from Milan and 600 km from Barcelona. The residents of the city are called *Lyonnais* (singular and plural).
Lyon is a major center of business with a reputation as the French capital of *gastronomy* and having a significant role in the history of cinema due to *Auguste and Louis Lumière*. The local professional football team, *Olympique Lyonnais*, has increased the profile of Lyon internationally through participation in European football championships.
Together with its suburbs and satellite towns, Lyon forms the second-largest metropolitan area in France after that of Paris, with the population of its urban area estimated to be 1,783,400 and that of its metropolitan area 4,415,000^[1] (2007). Its urban region (*Urban Community of Lyon*), represents half of the Rhône-Alpes région population with three million inhabitants^[2]. Lyon is also a major industrial center specializing in chemical, pharmaceutical, and biotech industries. The city also contains a significant software industry with a particular focus on video games.

The page includes a "Contents" sidebar with links to various sections like History, Geography, Culture, Economy, Main sights, Colleges and universities, Sport, Transport, and International attraction. It also features a "City flag" (red with three yellow stars) and a "City coat of arms" (a lion rampant on a shield).


The right sidebar provides geographical information: "Coordinates: 45°45'35"N 4°50'32"E", "Motto: Avant, avant, Lyon le meilleur. (Arpitan: Forward, forward, Lyon the best)", a photo of Lyon from Fourvière, a map showing Lyon's location in France, and administrative details:

Time zone	CET (GMT+1)
Administration	
Country	France
Region	Rhône-Alpes
Department	Rhône (69)
Arrondissement	Lyon
Canton	chief town of 14 cantons
Subdivisions	9 arrondissements
Intercommunality	Urban Community of Lyon

2. RDF : des données aux données liées




2. RDF : des données aux données liées



Données vues comme un graphe

2. RDF : Des données aux données liées



Données vues comme un graphe avec des IRIs

2. RDF : syntaxe abstraite

Toute information en RDF est représentée par un *triplet*, signifiant qu'une *chose* est en *relation* avec une autre.

Exemple :

Le laboratoire LIRIS (**sujet**)

a pour membre (**prédicat**)

Pierre-Antoine Champin (**objet**)

2. RDF : syntaxe abstraite


Les choses sont nommées par des IRIs :

<http://liris.cnrs.fr/#lab>

<http://xmlns.com/foaf/0.1/member>

<http://champin.net/#pa>

On peut représenter ceci graphiquement :



2. RDF : préfixes

Pour simplifier les **notations**, on définit des préfixes courts correspondant à des préfixes d'IRI :

liris: → http://liris.cnrs.fr/#


foaf: → http://xmlns.com/foaf/0.1/

champin: → http://champin.net/#

On utilise ensuite des *noms prefixés* :

liris:lab foaf:member champin:pa

et également sous forme graphique :




2. RDF : les littéraux

On peut également lier une ressource à une *donnée typée* (chaîne de caractères, entier, réel...), nommée un littéral.

champin:pa foaf:name "Pierre-Antoine Champin"

Traditionnellement, on représente les littéraux par des nœuds rectangulaires :




2. RDF : les nœuds muets

Enfin, RDF permet de parler d'une ressource sans connaître son IRI. Cela revient en logique à utiliser une variable quantifiée existentiellement.

(quelque chose) foaf:name "Stéphane Derrode"

On parle alors de nœud *muet* (par analogie aux variables muettes). Graphiquement, on représente cette ressource par un nœud vierge (*blank node*).




2. RDF : exemple de graphe

Enfin, RDF permet de parler d'une ressource sans connaître son IRI. Cela revient en logique à utiliser une variable quantifiée existentiellement.


(quelque chose) foaf:name "Stéphane Derrode"

On parle alors de nœud *muet* (par analogie aux variables muettes). Graphiquement, on représente cette ressource par un nœud vierge (*blank node*).



2. RDF : les nœuds muets

Un ensemble de triplets forme un graphe orienté étiqueté.



2. RDF : syntaxes concrètes

RDF / XML

- syntaxe originale recommandée par le W3C (1999)
- basée sur XML
- relativement complexe et verbeuse

Syntaxe : <http://www.w3.org/TR/rdf-syntax-grammar/>

Validator : <http://www.w3.org/RDF/Validator/>

2. RDF : syntaxes concrètes

RDF / XML : exemple

```
<rdf:RDF xmlns:rdf="http://www.w3.org/1999/02/22-rdf-syntax-ns#"
           xmlns:foaf="http://xmlns.com/foaf/0.1/"
    <foaf:Group rdf:about="http://liris.cnrs.fr/#lab">
        <foaf:member>
            <foaf:Person>
                <foaf:name>Stéphane Derrode</foaf:name>
                <foaf:knows
                    rdf:resource="http://champin.net/#pa"/>
                </foaf:Person>
            </foaf:member>
            <foaf:member>
                <foaf:Person rdf:about="http://champin.net/#pa">
                    <foaf:name>Pierre-Antoine Champin</foaf:name>
                </foaf:Person>
            </foaf:member>
        </foaf:Group>
    </rdf:RDF>
```

2. RDF : syntaxes concrètes

RDF / Turtle

- dérivée du langage [N3](#)
- adoptée dans RDF 1.1 en 2014
- vise la simplicité et la compacité

Syntaxe : <http://www.w3.org/TR/turtle/>

Validator : <http://www.rdfabout.com/demo/validator/>

2. RDF : syntaxes concrètes

RDF / turtle : exemple

```
@prefix foaf: <http://xmlns.com/foaf/0.1/> .
@prefix champin: <http://champin.net/#> .

liris:lab
  a foaf:Group ;
  foaf:member champin:pa, _:sd .
champin:pa
  a foaf:Person ;
  foaf:name "Pierre-Antoine Champin" .
_:sd
  a foaf:Person ;
  foaf:name "Stéphane Derrode" ;
  foaf:knows champin:pa .
```

2. RDF : syntaxes concrètes

RDF / JSON

- Rappel : JSON est un langage d'échange de données, basé sur Javascript, et très utilisé en développement web.
- JSON-LD (JSON Linked Data) permet d'interpréter une structure JSON comme du RDF, grâce à un *contexte* (implicite ou explicite).
- Objectif : faciliter l'adoption de RDF (syntaxe abstraite) auprès des développeurs d'applications web.

Syntaxe : <http://www.w3.org/TR/json-ld-syntax/>

Validator : <http://json-ld.org/playground/>

2. RDF : syntaxes concrètes

RDF / JSON : exemple

```
{ "@context": { /* ... */ },  
  "@id": "http://liris.cnrs.fr/#lab",  
  "@type": "Group",  
  "member": [  
    {  
      "@id": "http://champin.net/#pa",  
      "@type": "Person",  
      "name": "Pierre-Antoine Champin"  
    },  
    {  
      "@type": "Person",  
      "name": "Stéphane Derrode",  
      "knows": "http://champin.net/#pa"  
    }  
  ]  
}
```


3. SparQL : objectifs

- Vous donner des bases pour écrire des requêtes SPARQL.
- Bonus: lire/écrire du Turtle (très proche de SPARQL).
- Ce n'est qu'une introduction ; pour en savoir plus :

<http://www.w3.org/TR/sparql11-overview/>


3. SparQL : requête simple

- Considérons les données suivantes



3. SparQL : requête simple

```
PREFIX foaf: <http://xmlns.com/foaf/0.1/>
SELECT ?n1 ?n2
WHERE {
    ?p1 a foaf:Person;
        foaf:name ?n1;
        foaf:knows ?p2.
    ?p2 a foaf:Person;
        foaf:name ?n2.
}
```



3. SparQL : requête simple

```
PREFIX foaf: <http://xmlns.com/foaf/0.1/>
SELECT ?n1 ?n2
WHERE {
    ?p1 a foaf:Person;
        foaf:name ?n1;
        foaf:knows ?p2.
    ?p2 a foaf:Person;
        foaf:name ?n2.
}
```

n1	n2
Alice	Bob
Carol	Dan
Dr Jekyll	Dan
Mr Hide	Dan

3. SparQL : description

Préfixes : les préfixes servent à abréger les IRIs.

```
PREFIX foaf: <http://xmlns.com/foaf/0.1/>
```

```
PREFIX : <http://example.com/>
```

Termes

IRI en extension (relatif ou absolu) :

```
<http://xmlns.org/foaf/0.1/Person>
<../other-file.rdf>
<#something>
<>
```

IRI abrégé :

```
foaf:Person
:something
```

3. SparQL : description

Littéraux :

```
"Hello"@en          # avec tag de langue
"123^^xsd:integer # typé

"Bonjour"           # equiv. "Bonjour"^^xsd:string
42                  # equiv. "42"^^xsd:integer
1.5                 # equiv. "1.5"^^xsd:decimal
314e-2              # equiv. "314e-2"^^xsd:double
true                # equiv. "true"^^xsd:boolean
```

Nœud muet :

```
_:toto
[]      # voir ci-après
```

Variables :

```
?x
$y
```

3. SparQL : triplets

- 3 termes (sujet, prédicat, objet) séparés par des espaces et suivis d'un point ":" :

```
?pl foaf:name "Pierre-Antoine Champin".
```

- Cas particulier : le mot clé "a" en position de prédicat est un raccourci pour <<http://www.w3.org/1999/02/22-rdf-syntax-ns#type>> :

```
?pl a foaf:Person.
```

3. SparQL : factorisation

- On peut « factoriser » plusieurs triplets ayant le même sujet en séparant les couples <prédicat, objet> par un point-virgule ";" :

```
?p1 a foaf:Person;
    foaf:givenName "Pierre-Antoine";
    foaf:familyName "Champin".
```

- On peut « factoriser » plusieurs triplets ayant le même sujet et le même prédicat en séparant les objets par une virgule "," :

```
?p1 a foaf:phone <tel:+33-472-44-82-40>,
    <tel:+33-472-49-21-73>.
```

- On peut bien sûr combiner les deux types de factorisation.
- On n'est jamais obligé de factoriser, on peut aussi répéter les termes.


3. SparQL : nœuds muets

- Lorsqu'un nœud muet n'a qu'un seul arc entrant, au lieu de lui inventer un identifiant local :

```
<#pa> foaf:knows _:quelqun.  
_:quelqun a foaf:Person;  
faof:name ?n.
```

- on peut utiliser la notation [] :

```
<#pa> foaf:knows [  
    a foaf:Person;  
    faof:name ?n.  
].
```



3. SparQL : union

- Pour exprimer un "ou" logique entre plusieurs contraintes, on place chaque alternative entre accolades, séparées par le mot-clé UNION :

```
<#pa> foaf:knows ?pl.  
{ ?pl a foaf:Person; foaf:name ?n}  
UNION  
{ ?pl a schema:Person; schema:name ?n}
```

3. SparQL : sous-graphe optionnel

On peut accepter qu'une partie du graphe ne soit pas satisfaite :

```
?p1 a foaf:Person;
    foaf:name ?n.
OPTIONAL {?p1 foaf:img ?img}
OPTIONAL {?p1 foaf:phone ?tel}
```

Ou

```
?p1 a foaf:Person;
    foaf:name ?n.
OPTIONAL {?p1 foaf:img ?img. ?p1 foaf:phone ?tel}
```

Dans le résultat, les variables des clauses optionnelles peuvent donc ne recevoir aucune valeur (null).

3. SparQL : filtres

On peut ajouter des contraintes sur les valeurs des résultats, avec la clause FILTER.

```
?p foaf:age ?a.  
FILTER (?a >=18)
```

On peut combiner des conditions avec les opérateurs logiques « et » (`&&`), « ou » (`||`) et « non » (`!`).

```
FILTER (?a >=18 && a<30)
```

3. SparQL : filtres / opérateurs et fonctions

- comparaisons : =, !=, <, >, <=, >=
- opérateurs arithmétiques : +, -, *, /
- nature d'un nœud : isIRI, isBLANK, isLITERAL, isNUMERIC
- vérifier qu'une variable (utilisée avec OPTIONAL) a bien une valeur : Bound
- recherche de texte : REGEX(<variable>, <texte>)

Pour plus d'information, consultez la [documentation de SPARQL](#).

3. SparQL : requête SELECT

Similaire au SELECT de SQL :

projection sur un sous-ensemble des variables du graphe

Résultat : tableau

une colonne par variable sélectionnée
une ligne par résultat

Structure :


SELECT <variables/expression> WHERE { <graphe> }

Les résultats du SELECT peuvent être des expressions complexes, calculées à partir des variables de la clause WHERE.

```
SELECT ?p (concat(?gn, " ", ?fn) as ?name)
WHERE {
    ?p foaf:givenName ?gn;
        foaf:familyName ?fn.
}
```

3. SparQL : Distinct

```
SELECT DISTINCT ?sn
WHERE {
  <#pa> foaf:knows ?p.
  ?p foaf:familyName ?sn.
}
```



Sans le DISTINCT, la requête renverra deux fois le résultat sn="Doe".

3. SparQL : LIMIT et OFFSET

Pour obtenir les 10 premiers résultats :

```
SELECT ?p
WHERE {
  <#pa> foaf:knows ?p.
} LIMIT 10
```

Pour obtenir les 5 résultats suivants :

```
SELECT ?p
WHERE {
  <#pa> foaf:knows ?p.
}
LIMIT 10
OFFSET 5
```

3. SparQL : ORDER BY

```
SELECT ?p ?n
WHERE {
  <#pa> foaf:knows [
    foaf:givenName ?p ;
    foaf:familyName ?n ]
}
ORDER BY ?n ?p
```

On peut aussi trier par ordre descendant :

```
SELECT ?name ?age
WHERE {
  <#pa> foaf:knows [
    foaf:name ?name ;
    foaf:age ?age ]
}
ORDER BY DESC(?age)
LIMIT 1
```

3. SparQL : GROUP BY

Sert à *aggréger* certaines valeurs avec l'une des fonctions d'aggrégations : Count, Sum, Avg, Min, Max, GroupConcat et Sample.

```
SELECT ?p1 (count(?p2) as ?cp2)
WHERE {
    ?p1 foaf:knows ?p2
}
GROUP BY ?p1
```

On peut combiner GROUP BY avec ORDER BY et LIMIT (attention à l'ordre) :

```
SELECT ?p1 (count(?p2) as ?cp2)
WHERE {
    ?p1 foaf:knows ?p2
}
GROUP BY ?p1
ORDER BY DESC(?cp2) LIMIT 3
```

3. SparQL : sous-requête

Il est possible d'inclure, dans une clause WHERE, une requête SELECT entre accolades.

Par exemple, la requête suivante donne, pour chaque personne, son écart par rapport à l'âge moyen.

```
SELECT ?p ((?age - ?ageMoyen) as ?ecart)
WHERE {
    ?p a foaf:Person ;
        foaf:age ?age.
{
    SELECT (avg(?age2) as ?ageMoyen) {
        ?p2 a foaf:Person ;
            foaf:age ?age2.
    }
}
}
```


3. SparQL : points d'accès

Point d'accès :

- DBpedia : <http://dbpedia.org/sparql>
- Nobel prizes : <http://data.nobelprize.org/sparql>
- Muziekweb :
<https://api.data.muziekweb.nl/datasets/MuziekwebOrganization/Muziekweb/services/Muziekweb/sparql>
- LOV : *list of vocabularies*
<https://lov.linkeddata.es/dataset/lov/sparql>

Liste des points d'accès :

- The Linked Open Data Cloud :
<https://lod-cloud.net>



3. SparQL : Exploration des ressources

Sur *Musiekweb*, la requête suivante

```
SELECT ?type
WHERE { ?o a ?type }
GROUP BY ?type
ORDER BY DESC(count(?o))
LIMIT 30
```

génère

	type
1	< https://data.muziekweb.nl/vocab/OrderInformation >
2	< http://schema.org/MusicAlbum >
3	< https://data.muziekweb.nl/vocab/Album >
4	< http://schema.org/MusicGroup >
5	< https://data.muziekweb.nl/vocab/PopularAlbum >
6	< https://data.muziekweb.nl/vocab/PopularPerformer >

3. SparQL : exploration des propriétés

Sur *Musiekweb*, la requête suivante

```
prefix vocab: <https://data.muziekweb.nl/vocab/>
SELECT DISTINCT ?prop
WHERE {
    ?o a vocab:Performer;
       ?prop ?val.
}
LIMIT 30 OFFSET 4
```

génère

	prop
1	vocab:album
2	vocab:alias
3	vocab:beginYear
4	vocab:contemporary
5	vocab:endYear

3. SparQL : Trouver un vocabulaire

- Faire une démo de *Linked open vocabularies*
<http://lov.okfn.org/>
- Requête à partir de LOV (*list of vocabularies*)

```
PREFIX vann:<http://purl.org/vocab/vann/>
PREFIX voaf:<http://purl.org/vocommons/voaf#>

### Vocabularies contained in LOV and their prefix
SELECT DISTINCT ?vocabPrefix ?vocabURI {
  GRAPH <https://lov.linkeddata.es/dataset/lov>{
    ?vocabURI a voaf:Vocabulary.
    ?vocabURI vann:preferredNamespacePrefix ?vocabPrefix.
  }
}
ORDER BY ?vocabPrefix
```

3. SparQL : Trouver un vocabulaire

	vocabPrefix	vocabURI
1	SAN	< http://www.irit.fr/recherches/MELODI/ontologies/SAN >
2	a-loc	< https://w3id.org/arco/ontology/location >
3	acco	< http://purl.org/acco/ns >
4	acl	< http://www.w3.org/ns/auth/acl >
5	acm	< http://www.rkbexplorer.com/ontologies/acm >

Il y a 723 résultats!